



TECNOLÓGICO  
NACIONAL DE MÉXICO



Instituto Tecnológico Nacional de México, campus Culiacán

Ingeniería en Sistemas Computacionales

**Green Sense: Modelo de detección temprana ante crisis hídricas  
en Sinaloa mediante NDVI, NDWI y NDDI.**

Protocolo de investigación para Tópicos de Inteligencia Artificial

Integrantes del proyecto:

Payan Urquidez Rafael Alberto

Quiñonez Ramirez Nestor de Jesus

Docente: Mora Felix Zuriel Dathan

Repositorio:

<https://github.com/Norkat/Topicos-de-Inteligencia-Artificial>

Culiacán, Sinaloa a 12 Septiembre del 2025

<b>Antecedentes del problema.....</b>	<b>2</b>
<b>Planteamiento del problema.....</b>	<b>3</b>
<b>Objetivo General.....</b>	<b>3</b>
<b>Objetivos Específicos.....</b>	<b>4</b>
<b>Justificación.....</b>	<b>4</b>
<b>Marco Teórico.....</b>	<b>4</b>
Marco Histórico.....	4
Inicios y Transición hacia un Enfoque Proactivo.....	5
Antecedentes de Monitoreo con Teledetección.....	5
Marco Conceptual.....	6
Conceptos del Problema.....	6
Variables de Teledetección y Datos de Entrada.....	6
Variables del Proceso de Entrenamiento y Calibración del Modelo.....	7
Variables de Salida y de Alerta.....	8
Marco Referencial.....	9
Teledetección y Monitoreo de Sequía Agrícola.....	9
Modelos Predictivos y Sistemas de Alerta Temprana.....	9
Brecha de Conocimiento y Justificación del Protocolo.....	10
<b>Hipótesis.....</b>	<b>10</b>
<b>Metodología.....</b>	<b>10</b>
Determinación del universo y obtención de la muestra.....	10
Determinación del Universo.....	11
Obtención de la Muestra.....	11
Determinación del tipo de estudio (Cuantitativo - Cualitativo).....	11
Selección de la metodología de desarrollo del prototipo.....	12
Justificación de la Metodología.....	12
Tecnologías a Utilizar.....	13
Tecnologías de Software.....	13
Plataformas y APIs de Acceso a Datos.....	14
<b>Plan de trabajo.....</b>	<b>15</b>
<b>Conclusión.....</b>	<b>16</b>
<b>Bibliografía.....</b>	<b>17</b>
Citas de revistas académicas.....	17
Referencias de sitios web y artículos en línea.....	17
Manual o guía técnica.....	20

## Antecedentes del problema

La crisis hídrica en México es un problema estructural que se ha agudizado en los últimos años. Más de la mitad del territorio nacional se clasifica como árido o semiárido, lo que lo hace intrínsecamente vulnerable a la sequía. En abril de 2021, el 85% del país experimentó condiciones de sequía, una de las más generalizadas en su historia reciente. Estadísticamente, los estados más afectados se encuentran en el norte y centro del país, como Sinaloa, Durango, Chihuahua y Coahuila. Esta situación se refleja en los niveles de almacenamiento de las presas, donde 122 de 209 presas principales se encuentran por debajo del 50% de su capacidad total.

Sinaloa, uno de los principales estados agrícolas de México, enfrenta desde hace varios años una grave crisis hídrica. En el ciclo agrícola 2024-2025, la escasez de lluvias y los niveles críticos de las presas han impactado drásticamente la producción de maíz, cultivo clave para el estado. Por ejemplo, la presa Luis Donaldo Colosio operaba en 2024 al 15.7 % de su capacidad. La Comisión Nacional del Agua reportó además que la prolongada sequía –catalogada como “excepcional”– motivó el cierre de cinco presas sinaloenses en abril de 2025, debido a que sus embalses cayeron a niveles históricos mínimos.

Desde 2023 más de la mitad del territorio de Sinaloa se mantiene en condiciones de sequía. Esta situación redujo drásticamente las superficies agrícolas sembradas –por ejemplo, sólo se planearon 49 000 ha de maíz en 2024-2025, frente a 290 000 ha en el ciclo anterior– y elevó los costos de producción, afectando la rentabilidad de los agricultores. En resumen, la región sufre una crisis hídrica que amenaza la seguridad alimentaria y el abastecimiento urbano.

Ante este panorama, la teledetección satelital ofrece herramientas útiles para monitorear estas condiciones mediante índices normalizados. El Índice de Vegetación de Diferencia Normalizada (NDVI) se utiliza para el monitoreo del crecimiento de los cultivos y la programación de riego, mientras que el Índice de Agua de Diferencia Normalizada (NDWI) ayuda a identificar masas de agua y zonas con alta humedad. Un ejemplo de su uso en México es el proyecto desarrollado en Jalisco, que utiliza el Índice de Sequía de Diferencia Normalizada (NDDI) para cuantificar la superficie de tierra agrícola afectada por la sequía, con el fin de analizar la tendencia a largo plazo y apoyar la toma de decisiones.

El modelo que proponemos es un protocolo de monitoreo continuo que utilizará los índices satelitales NDVI, NDWI y NDDI, junto con datos meteorológicos e hidrológicos, para generar alertas proactivas. A diferencia de los sistemas genéricos de monitoreo, este modelo no solo supervisará el estado actual, sino que emitirá alertas específicas cuando se alcancen umbrales de riesgo, permitiendo a los agricultores y gestores de recursos hídricos actuar antes de que el daño sea irreversible. Esto hará transicionar de una

gestión reactiva, que mitiga el daño una vez ocurrido, a una gestión proactiva que se anticipa a la crisis, mejorando la planificación y la resiliencia ante futuras sequías.

## Planteamiento del problema

La crisis hídrica en México, un problema estructural agravado por el cambio climático, ha alcanzado un punto crítico. Sinaloa, uno de los estados agrícolas más importantes del país, enfrenta una situación particularmente grave. La escasez de lluvias y los niveles históricamente bajos en las presas han impactado severamente la producción agrícola, un sector sumamente importante en el país.

Actualmente, la gestión de esta crisis es reactiva: las acciones se toman solo después de que la sequía ha causado daños significativos, como la reducción drástica de las superficies de cultivo y el aumento de los costos de producción. Este enfoque reactivo perpetúa un ciclo de pérdidas económicas y productivas, afectando la rentabilidad de los agricultores y la economía regional.

Esta situación subraya una deficiencia crítica: la ausencia de un sistema de alerta temprana que permita a los agricultores y gestores de recursos hídricos anticipar los efectos de la sequía. A diferencia de un enfoque reactivo, que mitiga el daño una vez ocurrido, un modelo proactivo podría generar alertas específicas al alcanzar umbrales de riesgo, permitiendo una planificación y toma de decisiones oportunas. Sin estas herramientas, la región seguirá siendo vulnerable a las sequías, comprometiendo no solo la agricultura, sino también el suministro de agua para consumo humano.

El modelo de detección se basa en el uso de índices de teledetección como el Índice de Vegetación de Diferencia Normalizada (NDVI), que mide la salud de la vegetación, el Índice de Agua de Diferencia Normalizada (NDWI), que evalúa la humedad del suelo y de la vegetación, y el Índice de Sequía de Diferencia Normalizada (NDDI), que combina los dos anteriores para cuantificar la severidad de la sequía. Al monitorear estos índices de forma continua y establecer umbrales de riesgo, el protocolo podrá generar alertas tempranas que permitan a los agricultores y gestores de recursos hídricos tomar medidas antes de que la sequía cause daños irreversibles. Esto hará transicionar de una gestión reactiva, que mitiga el daño una vez ocurrido, a una gestión proactiva que se anticipa a la crisis, mejorando la planificación y la resiliencia ante futuras sequías.

## Objetivo General

Desarrollar y validar un protocolo de monitoreo continuo que utilice la teledetección satelital y datos de campo para generar alertas proactivas, permitiendo una gestión más resiliente y anticipatoria de la crisis hídrica en el sector agrícola de Sinaloa.

## Objetivos Específicos

- Evaluar la correlación entre los índices satelitales (NDVI, NDWI, NDDI) y las condiciones de estrés hídrico en el sector agrícola en Sinaloa.
- Establecer umbrales de riesgo para cada índice satelital que sirvan como detonantes de alertas tempranas de sequía.
- Diseñar un sistema de alerta que integre datos de teledetección con datos meteorológicos e hidrológicos para emitir notificaciones específicas a agricultores y gestores de recursos hídricos.
- Validar la efectividad del protocolo de monitoreo mediante el seguimiento de su capacidad para predecir la sequía y su impacto en la producción agrícola en áreas piloto.

## Justificación

La falta de un sistema de alerta temprana basado en datos en tiempo real ha perpetuado un ciclo de gestión reactiva y costosa en el sector agrícola de Sinaloa. La implementación de este protocolo de monitoreo proactivo ofrece una solución escalable y sostenible, crucial para la resiliencia de la región ante futuras sequías.

Este enfoque no sólo mitigará las pérdidas económicas y de producción, sino que también mejorará la planificación de los ciclos agrícolas y la asignación de recursos hídricos. La información generada será vital para los tomadores de decisiones en el gobierno, las organizaciones agrícolas y los propios agricultores, promoviendo una agricultura más inteligente y adaptada al clima.

La teledetección, con su capacidad para monitorear grandes extensiones de tierra de manera eficiente, proporciona una base tecnológica sólida para este tipo de iniciativas. El uso de índices normalizados como NDVI, NDWI y NDDI permite una cuantificación precisa de la salud de la vegetación y la disponibilidad de agua, elementos clave para la detección temprana de la sequía. En resumen, este proyecto busca transformar un problema recurrente en una oportunidad para la innovación, asegurando la sostenibilidad a largo plazo de la agricultura sinaloense.

## Marco Teórico

### Marco Histórico

El enfoque de la gestión de la sequía en México ha evolucionado de un modelo puramente reactivo a uno que busca ser más preventivo, aunque con una implementación aún incipiente. La propuesta de un protocolo de monitoreo satelital en Sinaloa se inscribe en

esta transición, aprovechando los avances tecnológicos y los antecedentes de iniciativas similares.

## Inicios y Transición hacia un Enfoque Proactivo

Históricamente, la respuesta a la sequía se limitaba a medidas de emergencia, como la perforación de pozos y el envío de pipas de agua. Sin embargo, a raíz de las sequías extremas de principios del siglo XXI (especialmente la de 2011), las autoridades mexicanas reconocieron la necesidad de un cambio. En 2012, el gobierno federal emitió un decreto para una mejor coordinación y un enfoque proactivo, preventivo y basado en el riesgo. Este cambio de política impulsó el desarrollo de herramientas de monitoreo más sofisticadas.

## Antecedentes de Monitoreo con Teledetección

El uso de la teledetección satelital para la agricultura no es una idea completamente nueva en México. Instituciones como el Instituto Mexicano de Tecnología del Agua (IMTA) han explorado estas tecnologías para el monitoreo de la sequía. Por ejemplo, en colaboración con la FAO, se llevó a cabo un proyecto piloto en Zacatecas enfocado en el Sistema del Índice de Estrés Agrícola (ASIS). Esta iniciativa se centró en la calibración del sistema para el monitoreo de cultivos de temporal, demostrando la viabilidad de utilizar datos satelitales para detectar de manera temprana el estrés hídrico. Si bien el proyecto probó ser una herramienta eficaz para el diagnóstico, sus resultados no se tradujeron en un sistema operativo capaz de generar alertas directas para los productores.

De forma similar, un proyecto desarrollado en Jalisco utilizó el Índice de Sequía de Diferencia Normalizada (NDDI) para analizar la sequía. Esta iniciativa se distinguió por su enfoque en la cuantificación de la superficie afectada a lo largo del tiempo. Los resultados de esta implementación fueron exitosos para generar un análisis de tendencias a largo plazo y proveer información para la toma de decisiones a nivel de política pública, permitiendo a las autoridades comprender la evolución histórica del fenómeno. Sin embargo, al igual que en Zacatecas, el sistema no fue diseñado para emitir alertas en tiempo real o para integrarse con la operativa diaria de los agricultores, dejando una brecha entre el diagnóstico y la acción proactiva.

Estos esfuerzos han sido a menudo de carácter regional o con un objetivo particular, lo que no ha permitido una integración y enfoque específicos para la gestión proactiva de una crisis aguda como la de Sinaloa. El Monitor de Sequía de México de CONAGUA, por ejemplo, proporciona una visión nacional de las condiciones de sequía que es crucial para la toma de decisiones a nivel estratégico, como la declaración de emergencias o la asignación de recursos federales. Sin embargo, esta información no se traduce en alertas específicas y accionables para agricultores individuales o distritos de riego, y se enfoca en

la intensidad de la sequía ya presente en lugar de su predicción, dejando una brecha entre la información de alto nivel y la necesidad de acción directa en el campo.

## Marco Conceptual

El marco conceptual de esta investigación se sustenta en una serie de conceptos y variables técnicas que definen el proceso, desde la recolección de datos hasta la emisión de la alerta. Estos son los elementos que guían el desarrollo y la implementación del protocolo de monitoreo.

### Conceptos del Problema

- **Crisis Hídrica y Sequía Agrícola:** Este es el fenómeno central del estudio. Se entiende como una condición de escasez de agua que impacta negativamente en la producción agrícola. Esta crisis no es solo un evento natural, sino que se agrava por el uso intensivo del agua, el cambio climático y la falta de mecanismos de gestión proactiva.
- **Gestión Reactiva:** Es la respuesta tradicional a la sequía. Las acciones (como la asignación de ayuda o la limitación de siembra) se toman después de que el estrés hídrico ya ha afectado los cultivos y ha causado pérdidas económicas.
- **Gestión Proactiva:** El resultado deseado. La capacidad de los usuarios de anticiparse a la crisis hídrica, tomando medidas como ajustar el riego, utilizar otras fuentes de agua o planificar la siembra, antes de que el daño a los cultivos sea irreversible.

### Variables de Teledetección y Datos de Entrada

- **Teledetección:** La teledetección es la herramienta tecnológica fundamental para la gestión proactiva. Permite monitorear grandes áreas de forma no invasiva y en tiempo real. Los índices normalizados son las variables clave extraídas de las imágenes satelitales que actúan como indicadores del problema.
- **Índice de Vegetación de Diferencia Normalizada (NDVI):** Es una medida cuantitativa del vigor de la vegetación a partir de las bandas de reflectancia del rojo (Red) y el infrarrojo cercano (NIR). Su fórmula es:  $NDVI = (NIR - Red) / (NIR + Red)$ . Los valores oscilan entre -1 y 1. Un valor alto (cercano a 1) indica vegetación densa y saludable, mientras que un valor bajo (cercano a 0) sugiere estrés o poca biomasa, en caso de ser un valor negativo (cercano a -1), es un indicativo de ausencia total de vegetación saludable.
- **Índice de Agua de Diferencia Normalizada (NDWI):** Mide el contenido de agua en las hojas y el suelo, utilizando las bandas del infrarrojo cercano (NIR) y el infrarrojo

de onda corta (SWIR). Su fórmula es:  $NDWI = (NIR - SWIR) / (NIR + SWIR)$ . Es un indicador de la humedad del agua en el terreno, con valores que varían entre -1 y 1. Los valores más altos, que se acercan a 1, corresponden a cuerpos de agua libres, como ríos y lagos. Los valores cercanos a cero indican que hay poca humedad en el suelo, mientras que los valores negativos, que se aproximan a -1, representan superficies secas y sin vegetación.

- Índice de Sequía de Diferencia Normalizada (NDDI): Es un índice compuesto que integra la información del NDVI y el NDWI para cuantificar la severidad de la sequía. Su fórmula es:  $NDDI = (NDVI - NDWI) / (NDVI + NDWI)$ . Su valor oscila entre -1 y 1. Un NDDI alto (cercano a 1) indica que la vegetación es sana y hay un alto contenido de humedad. Por el contrario, un NDDI bajo o negativo (cercano a -1) es un fuerte indicador de sequía severa, ya que la vegetación está estresada y hay una baja disponibilidad de agua.
- Datos Meteorológicos e Hidrológicos: Variables de campo cruciales para la calibración del modelo, incluyendo precipitación acumulada, temperatura del aire y niveles de almacenamiento de presas.

## Variables del Proceso de Entrenamiento y Calibración del Modelo

- Variable Predictora (Feature): Es el conjunto de datos de entrada utilizado para entrenar el modelo. En este caso, serían los valores de los índices satelitales (NDVI, NDWI, NDDI) a lo largo del tiempo, junto con los datos meteorológicos e hidrológicos.
- Variable Objetivo (Target Variable): Es la variable que el modelo busca predecir. Puede ser un índice de estrés hídrico validado en campo, o una clasificación binaria de "sequía" vs. "no sequía" en una zona específica.
- Algoritmo de Aprendizaje Automático (Machine Learning Algorithm): El modelo que aprenderá a encontrar la relación entre las variables predictoras y la variable objetivo. Usando algoritmos como Random Forest y Gradient Boosting para la clasificación o regresión.
- Random Forest (Bosques Aleatorios): Es un algoritmo versátil que funciona creando múltiples "árboles de decisión" y combinando sus resultados. Cada árbol se entrena con un subconjunto de los datos seleccionados aleatoriamente. Al hacer una predicción, el algoritmo toma la "votación" de todos los árboles para determinar la respuesta final. Este enfoque reduce el sobreajuste (overfitting) y mejora la precisión general del modelo.
- Gradient Boosting (Potenciación del Gradiente): Es un algoritmo que construye un modelo combinando múltiples árboles de decisión, pero de una manera secuencial.



A diferencia de Random Forest, donde los árboles se crean de forma independiente, en Gradient Boosting, cada nuevo árbol se entrena para corregir los errores del árbol anterior. Se enfoca en los errores "residuales" que el modelo previo no pudo capturar. El resultado es un modelo que mejora continuamente su precisión, pero que también puede ser más susceptible al sobreajuste si no se ajusta correctamente. Este algoritmo es muy potente para problemas de predicción precisos.

- Entrenamiento del Modelo: Proceso en el cual el algoritmo de aprendizaje automático utiliza los datos históricos de las variables predictoras y objetivo para "aprender" a identificar patrones de sequía.
- Validación Cruzada (Cross-Validation): Técnica utilizada para evaluar el rendimiento del modelo. Consiste en dividir los datos en subconjuntos de entrenamiento y prueba para asegurar que los resultados sean robustos y no estén sesgados por la muestra de datos.
- Umbrales de Riesgo: Valores específicos de los índices (como el NDDI) o de la salida del modelo que, al ser alcanzados, activan la emisión de una alerta. Por ejemplo, un NDDI por debajo de 0.2 podría considerarse un umbral de "sequía moderada" y activaría una notificación.

## Variables de Salida y de Alerta

- Sistema de Alerta Temprana: El producto final del modelo. Es la plataforma automatizada que integra todas las variables, ejecuta el modelo entrenado y, al detectar que se ha superado un umbral de riesgo, genera una alerta.
- Notificación Específica: El mensaje de alerta que se envía al usuario final (agricultor, gestor de recursos). Debe ser accionable, es decir, no solo debe informar sobre la sequía, sino también sugerir una medida a tomar.

La crisis hídrica genera un problema que actualmente es manejado de forma reactiva. La solución propuesta es un cambio a la gestión proactiva, que es posible a través del uso de la teledetección satelital. La información de esta tecnología es procesada mediante el entrenamiento de un modelo de aprendizaje automático, utilizando algoritmos como Random Forest y Gradient Boosting, que aprenden de los datos históricos para identificar patrones de sequía y predecir condiciones de riesgo. El modelo resultante forma el núcleo de un sistema de alerta temprana, que permite la toma de decisiones anticipadas y cierra el ciclo entre el diagnóstico del problema y la acción eficaz.

## Marco Referencial

El marco referencial de esta investigación se sustenta en la revisión de la literatura científica y los proyectos existentes a nivel nacional e internacional. Su objetivo es demostrar que la propuesta no parte de cero, sino que se basa en el conocimiento acumulado y busca llenar una brecha identificada en la investigación actual.

## Teledetección y Monitoreo de Sequía Agrícola

La teledetección satelital se ha consolidado como una herramienta fundamental para el monitoreo de la vegetación y las condiciones hídricas a gran escala. Estudios globales han demostrado la eficacia de los índices normalizados como el NDVI para evaluar la salud de los cultivos y el NDWI para mapear la disponibilidad de agua. A nivel regional, investigaciones en México han validado el uso de estas tecnologías. Por ejemplo, en Jalisco, se ha documentado un proyecto para el "Análisis de la sequía por medio del cálculo del Índice de Sequía de Diferencia Normalizada (NDDI)", que ha permitido cuantificar la superficie agrícola afectada y analizar tendencias a largo plazo. De igual manera, el Instituto Mexicano de Tecnología del Agua (IMTA), en colaboración con la FAO, ha llevado a cabo proyectos para la implementación de sistemas de monitoreo como el Sistema del Índice de Estrés Agrícola (ASIS) en estados como Zacatecas, demostrando la viabilidad de utilizar datos satelitales para la detección temprana del estrés hídrico. Sin embargo, estas aplicaciones han estado más orientadas al análisis de tendencias históricas y la planificación a nivel gubernamental que a la emisión de alertas en tiempo real para el agricultor.

## Modelos Predictivos y Sistemas de Alerta Temprana

La literatura muestra un creciente interés en el uso de modelos de aprendizaje automático para predecir eventos climáticos extremos. Diversas investigaciones han demostrado la efectividad de algoritmos como Random Forest y Gradient Boosting en la predicción de sequías y rendimientos de cultivos en diferentes partes del mundo. Por ejemplo, estudios como "Machine learning-based drought prediction using Palmer Drought Severity Index..." en Etiopía y "Evaluation of machine learning approaches for large-scale agricultural drought forecasts..." En Brasil han utilizado Random Forest para predecir el impacto de la sequía en la vegetación, superando a los modelos estadísticos tradicionales en precisión y robustez. De igual forma, en Turquía y Pakistán, investigaciones como "Drought classification using gradient boosting decision tree" y "Utilising machine learning classification models for meteorological drought monitoring and analysis" han empleado Gradient Boosting para la clasificación y predicción de la sequía meteorológica y agrícola con resultados de alta precisión, a menudo superando a otros algoritmos.

Estos estudios han sentado las bases teóricas para la construcción de sistemas de alerta temprana. La mayoría de estos sistemas se enfocan en la predicción de eventos a escala

regional, pero la implementación de modelos que integren múltiples variables (satelitales, hidrológicas y meteorológicas) para generar alertas a nivel de parcela agrícola es aún un área con un potencial de exploración considerable.

## Brecha de Conocimiento y Justificación del Protocolo

A pesar de la existencia de valiosos antecedentes, existe una brecha fundamental en el conocimiento y la aplicación tecnológica que este proyecto busca abordar. Mientras que los sistemas existentes en México ofrecen diagnósticos útiles de la sequía, no han logrado transicionar a un modelo proactivo, predictivo y localizado. No hay un protocolo estandarizado que:

- Combine de manera efectiva los tres índices principales (NDVI, NDWI, NDDI) con datos de campo.
- Establezca umbrales de riesgo específicos para la región de Sinaloa.
- Genere alertas automáticas y accionables para el usuario final (el agricultor), permitiendo una gestión anticipatoria del riesgo.

Esta investigación contribuirá a la literatura y a la práctica al desarrollar y validar un protocolo que cierra esta brecha, ofreciendo una solución que pasa de la mera descripción de la sequía a la predicción y mitigación de sus efectos, fortaleciendo la resiliencia agrícola en una de las zonas más vulnerables de México.

## Hipótesis

*“La implementación de un protocolo de monitoreo satelital continuo, que integre los índices de teledetección (NDVI, NDWI y NDDI) con datos meteorológicos e hidrológicos, permitirá una gestión proactiva de la crisis hídrica en la agricultura de Sinaloa, ya que el sistema será capaz de anticipar los periodos de sequía y emitir alertas tempranas, lo que se traducirá en una mitigación efectiva de sus efectos negativos sobre la producción agrícola.”*

## Metodología

### Determinación del universo y obtención de la muestra

La determinación del universo y la obtención de la muestra son pasos cruciales para asegurar que los resultados de la investigación sean representativos y válidos. Aquí se detalla cómo se abordarán estos puntos en el protocolo.

## Determinación del Universo

El universo de esta investigación se define como el conjunto total de parcelas agrícolas con siembra en el estado de Sinaloa durante el ciclo agrícola 2025-2026. Dada la gran extensión geográfica del estado y la alta densidad de cultivos, este universo es de gran magnitud.

El universo de estudio se delimitará en función de los Distritos de Riego (DR) y las Unidades de Producción y Riesgo (UPR) más afectados por la crisis hídrica, según los datos históricos de sequía. Se priorizará aquellas zonas que dependen directamente del agua de las presas con bajos niveles de almacenamiento.

## Obtención de la Muestra

Para la obtención de la muestra, se utilizará un muestreo no probabilístico intencional o por conveniencia. Esto se debe a que la investigación no busca hacer una generalización estadística a todo el estado, sino validar la efectividad del protocolo en áreas específicas y representativas del problema.

Se seleccionarán parcelas piloto dentro de los Distritos de Riego y Unidades de Producción previamente delimitadas. Estas parcelas serán elegidas bajo los siguientes criterios:

- Disponibilidad de Datos: Parcelas con registros históricos de siembra, riego y rendimiento de maíz.
- Representatividad: Se seleccionarán parcelas que muestran un rango de condiciones de estrés hídrico, desde aquellas con acceso constante al agua hasta las que han sufrido los efectos de la sequía.
- Acceso y Colaboración: Se priorizará la selección de parcelas cuyos agricultores estén dispuestos a colaborar en la recopilación de datos de campo y en el seguimiento del protocolo.

La muestra consistirá en un número determinado de hectáreas que serán monitoreadas de forma continua a lo largo del ciclo agrícola. En estas parcelas se implementará la recopilación de datos de campo para calibrar y validar los resultados obtenidos por el modelo de teledetección.

## Determinación del tipo de estudio (Cuantitativo - Cualitativo)

El tipo de estudio de esta investigación es cuantitativo. Esta elección metodológica es fundamental para el diseño del protocolo, ya que el objetivo principal es medir, analizar y validar la efectividad de un sistema de alerta temprana basado en datos.

Un estudio es cuantitativo cuando se enfoca en la recolección y análisis de datos numéricos para probar una hipótesis. A diferencia de los estudios cualitativos, que se centran en la comprensión de fenómenos a través de la interpretación de narrativas y experiencias, el enfoque cuantitativo busca establecer relaciones de causa y efecto, medir variables y generalizar resultados a través de la estadística.

El presente protocolo de investigación debe ser cuantitativo porque su propósito no es explorar la percepción de los agricultores sobre la sequía, sino validar la capacidad predictiva y el impacto real de una solución tecnológica. Para ello, se requiere:

- Cuantificar los valores de los índices de teledetección (NDVI, NDWI, NDDI) a lo largo del ciclo agrícola.
- Analizar la correlación estadística entre los datos satelitales, las variables de campo y el estrés hídrico.
- Evaluar la precisión del modelo de aprendizaje automático en la predicción de la sequía.
- Calcular el beneficio económico de la gestión proactiva en comparación con la reactiva.

Todas estas variables son numéricas y su análisis se realizará a través de métodos estadísticos, lo que asegura la objetividad y la validez de los resultados. Por lo tanto, el enfoque cuantitativo es el único que permitirá determinar de manera rigurosa si el protocolo propuesto es una solución efectiva y cuantificable para la gestión de la crisis hídrica en la agricultura.

## Selección de la metodología de desarrollo del prototipo

Para el desarrollo del prototipo de este protocolo, se propone la metodología Desarrollo Rápido de Aplicaciones (RAD). Este enfoque se justifica por su énfasis en la entrega rápida de un prototipo funcional, la flexibilidad y la colaboración activa con los usuarios finales (los agricultores).

### Justificación de la Metodología

La metodología RAD se adapta de manera ideal a las necesidades de esta investigación por las siguientes razones:

- Enfoque Iterativo y Modular: El desarrollo no se realiza en una sola fase larga, sino en ciclos cortos y repetitivos. Esto permite construir el prototipo por módulos (por ejemplo, primero el módulo de cálculo de índices satelitales, luego el de alertas, y

finalmente el de visualización). Cada iteración produce una versión mejorada y funcional del prototipo.

- **Entrega de Valor Temprana:** A diferencia de metodologías más tradicionales, RAD se enfoca en entregar un prototipo funcional en un corto periodo de tiempo. Esto es crucial para la investigación, ya que permite a los investigadores y a los usuarios probar el sistema y obtener retroalimentación valiosa de manera temprana, lo que asegura que el producto final sea relevante y útil.
- **Colaboración Activa del Usuario:** La metodología RAD promueve la participación constante de los usuarios. En este caso, la retroalimentación de los usuarios es fundamental para calibrar los umbrales de riesgo y asegurar que las alertas sean comprensibles y accionables en el campo. Su participación en cada etapa de desarrollo garantiza que el prototipo se adapte a sus necesidades reales.
- **Flexibilidad ante el Cambio:** El desarrollo de un prototipo de monitoreo de sequía en una región tan dinámica como Sinaloa requiere la capacidad de adaptarse a nuevas variables y descubrimientos. La flexibilidad de RAD permite ajustar los requisitos y el diseño en tiempo real, sin comprometer el cronograma del proyecto.

## Tecnologías a Utilizar

El protocolo de investigación requerirá un conjunto de tecnologías clave para recolectar, procesar, analizar y visualizar los datos, así como para generar y distribuir las alertas. Estas se dividen en tecnologías de hardware y software.

### Tecnologías de Software

- **Plataformas de Computación en la Nube:** Se necesitará una infraestructura robusta para procesar grandes volúmenes de datos satelitales. Plataformas como Google Earth Engine (GEE) o Amazon Web Services (AWS) son las más adecuadas. GEE, en particular, ofrece un catálogo masivo de imágenes satelitales y herramientas de procesamiento integradas, lo que acelera el cálculo de los índices.
- **Lenguajes de Programación:** Python es el lenguaje indicado para proyectos de Inteligencia Artificial. Cuenta con librerías potentes como NumPy, Pandas y Scikit-learn, que son esenciales para el análisis de datos, el entrenamiento de modelos de aprendizaje automático y la manipulación de datos geográficos.
- **Bases de Datos Espaciales:** Se utilizarán bases de datos especializadas como PostGIS para almacenar y gestionar de forma eficiente los datos georreferenciados de las parcelas piloto, los índices satelitales y los datos de campo.

- Plataforma de Alertas y Visualización: Se desarrollará una interfaz de usuario para la visualización de los mapas de sequía y la emisión de alertas. Tecnologías como JavaScript y frameworks como React o Django son ideales para construir esta plataforma.

## Plataformas y APIs de Acceso a Datos

Las siguientes son las principales fuentes para acceder a los datos meteorológicos, hidrológicos e imágenes satelitales necesarias para el proyecto:

- Google Earth Engine (GEE): Esta es la plataforma más recomendada para un proyecto de esta escala. Es un motor de computación en la nube que tiene un catálogo masivo de datos satelitales (incluyendo Sentinel y Landsat) y herramientas de análisis geoespacial. Su principal ventaja es que te permite procesar petabytes de datos directamente en la nube sin tener que descargarlos. GEE ofrece una API en Python y JavaScript, ideal para la automatización del protocolo.
- Copernicus Data Space Ecosystem: Este es el portal oficial de la Agencia Espacial Europea (ESA) para la misión Copernicus. Ofrece un acceso libre y abierto a todos los productos de Sentinel. El portal proporciona varias APIs, como la Sentinel Hub API y la STAC API, que permiten buscar, visualizar y descargar datos de manera programática.
- Servicio Geológico de los Estados Unidos (USGS) y NASA: Para los datos de Landsat, el USGS es la fuente principal. A través de su portal EarthExplorer, podemos acceder y obtener los datos, teniendo herramientas para acceder de manera automatizada a la información, usando Machine-to-Machine (M2M) API o su Spatio Temporal Asset Catalog (STAC) API.

# Plan de trabajo

ID de Tarea	Fase	Tarea	Responsable	Fecha de Inicio	Fecha de Finalización	Duración (días)
Fase 1: Preparación y conceptualización						
1.1	Preparación	Revisión de literatura y marco teórico	Investigador principal	15/09/2025	29/09/2025	15
1.2	Preparación	Definición del problema y objetivos	Investigador principal y Asistente de investigación	30/09/2025	06/10/2025	7
Fase 2: Recopilación y preprocesamiento de datos						
2.1	Recopilación	Acceso a datos satelitales	Asistente de investigación	07/10/2025	21/10/2025	15
2.2	Procesamiento	Procesamiento de imágenes	Asistente de investigación	22/10/2025	04/11/2025	14
2.3	Preprocesamiento	Integración de bases de datos espaciales	Investigador principal	05/11/2025	12/11/2025	8
Fase 3: Desarrollo y entrenamiento del modelo						
3.1	Desarrollo	Selección del modelo de aprendizaje automático	Investigador principal y Asistente de investigación	13/11/2025	26/11/2025	14
3.2	Entrenamiento	Entrenamiento y validación del modelo	Investigador principal y Asistente de investigación	27/11/2025	11/12/2025	15
Fase 4: Despliegue, análisis y resultados						
4.1	Despliegue	Visualización de resultados	Asistente de investigación	12/12/2025	25/12/2025	14
4.2	Análisis	Análisis y discusión de resultados	Investigador principal y Asistente de investigación	26/12/2025	01/01/2026	7
4.3	Conclusiones	Conclusiones y recomendaciones	Investigador principal	02/01/2026	09/01/2026	8



## Conclusión

Este protocolo de investigación establece un enfoque integral para enfrentar la sequía en Sinaloa, utilizando tecnologías de teledetección satelital para crear un modelo predictivo robusto. La base del sistema es la información de misiones como Sentinel-2 y Landsat, que permiten calcular índices clave como el NDVI y el NDWI. Esta información, procesada en plataformas en la nube como Google Earth Engine, sirve para entrenar modelos de aprendizaje automático capaces de predecir las condiciones de sequía.

El objetivo final es transformar un diagnóstico complejo en una solución práctica y accionable. Al desarrollar un sistema de alerta temprana que traduzca la información técnica en notificaciones comprensibles para los agricultores, el protocolo busca cambiar la gestión de la crisis de una respuesta reactiva a una proactiva. Esto permitirá a los productores tomar decisiones informadas sobre el manejo de los cultivos, lo que se traducirá en una mitigación efectiva de las pérdidas y en una mayor resiliencia para el sector agrícola de la región.

# Bibliografía

## Citas de revistas académicas

- Ahmad, A., & Ahmad, I. (2020). Utilising machine learning classification models for meteorological drought monitoring and analysis. *Environmental Systems Research*, 9(1). <https://link.springer.com/article/10.1186/s40068-020-00179-6>
- Mekonnen, A., & Admassu, Y. (2021). Machine learning-based drought prediction using Palmer Drought Severity Index and TerraClimate data in Ethiopia. *PLOS ONE*, 16(12), e0261742. <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0261742>
- Smith, J., & Lee, D. (2019). Evaluation of machine learning approaches for large-scale agricultural drought forecasts. *Natural Hazards and Earth System Sciences*, 19(12), 2763–2779. <https://nhess.copernicus.org/articles/19/2763/2019/>
- Yilmaz, K., & Demirci, M. (2022). Drought classification using gradient boosting decision tree. *Environmental Earth Sciences*, 81(3). <https://link.springer.com/article/10.1007/s12665-022-10314-4>

## Referencias de sitios web y artículos en línea

- Arable. (2023). Guía del Índice de Vegetación de Diferencia Normalizada (NDVI). <https://www.arable.com/blog/guia-del-indice-de-vegetacion-de-diferencia-normalizada/>
- BigCode. (2024, 31 de mayo). Guía completa de Scikit-Learn: Machine Learning en Python. <https://bigcode.es/guia-completa-de-scikit-learn-machine-learning-en-python/>
- Centro Nacional de Prevención de Desastres (CENAPRED). (2025). ¿Qué regiones del país son las más afectadas por las sequías?. <https://www.gob.mx/cenapred/articulos/que-regiones-del-pais-son-las-mas-afectadas-por-las-sequias>
- CIMMYT. (2024, 20 de noviembre). Crisis hídrica en Sinaloa: desafíos y respuestas desde el campo. <https://www.cimmyt.org/es/noticias/crisis-hidrica-en-sinaloa-desafios-y-respuestas-desde-el-campo/>
- CienciaDeDatos.net. (2023, febrero). Machine learning con Python y Scikit-learn. [https://cienciadedatos.net/documentos/py06\\_machine\\_learning\\_python\\_scikitlearn](https://cienciadedatos.net/documentos/py06_machine_learning_python_scikitlearn)

- Comisión Nacional del Agua (CONAGUA). (s. f.). Monitor de sequía de México. Servicio Meteorológico Nacional. <https://smn.conagua.gob.mx/es/climatologia/monitor-de-sequia/monitor-de-sequia-en-mexico>
- Coparmex. (s. f.). México en crisis por falta de agua. <https://coparmex.org.mx/mexico-en-crisis-por-falta-de-agua/>
- Copernicus Data Space Ecosystem. (2025). Explore data. <https://dataspace.copernicus.eu/explore-data>
- CursoGeol. (2025). Monitoreo hidrológico y de sequías con Google Earth Engine. <https://cursogeol.com/curso/monitoreo-hidrologico-y-de-sequias-con-google-earth-engine/>
- DataCamp. (2024, 11 de septiembre). Aprendizaje automático en Python: Tutorial de Scikit-Learn. <https://www.datacamp.com/es/tutorial/machine-learning-python>
- DiagramasUML. (2019, 10 de enero). Desarrollo rápido de aplicaciones (RAD): ¿Qué es y cómo funciona?. <https://diagramasuml.com/desarrollo-rapido-de-aplicaciones-rad-que-es-y-como-funciona/>
- EOS Data Analytics. (2023, 11 de julio). NDWI: Fórmula del índice e interpretación de valores. <https://eos.com/es/make-an-analysis/ndwi/>
- EOS Data Analytics. (2025, 28 de mayo). ¿Qué es el Índice de Vegetación de Diferencia Normalizada (NDVI)?. <https://eos.com/es/blog/indice-de-vegetacion-de-diferencia-normalizada-o-ndvi/>
- Flores Rojas, B. A. (2021). Sistemas de desarrollo: Observación satelital aplicada a detección de sequías. [https://eo4society.esa.int/wp-content/uploads/2021/11/CRECTEALC\\_Intro-Sequia\\_B\\_Flores.pdf](https://eo4society.esa.int/wp-content/uploads/2021/11/CRECTEALC_Intro-Sequia_B_Flores.pdf)
- FutureWater. (2025). Alerta temprana de sequía. <https://www.futurewater.es/projecttool/alerta-temprana-de-sequia/>
- Guru99. (2025, 23 de mayo). ¿Qué es el modelo RAD? Fases, Ventajas y Desventajas. <https://www.guru99.com/es/what-is-rad-rapid-software-development-model-advantages-disadvantages.html>
- Hydrosafe. (2025). Monitoreo de recursos hídricos por satélite. <https://www.hydrosafe.com.mx/services/monitoreo-de-recursos-hidricos-por-satelite/>

- Incentro. (2019, 26 de diciembre). Metodología RAD o DRA. El Desarrollo Rápido de Aplicaciones. <https://www.incentro.com/es-ES/blog/metodologia-rad-desarrollo-rapido-aplicaciones>
- Instituto de Información Estadística y Geográfica del Estado de Jalisco (IIEG). (2020). Análisis de la sequía en Jalisco por medio del cálculo del Índice de Sequía de Diferencia Normalizada (NDDI) 2015–2020. <https://iieg.gob.mx/ns/wp-content/uploads/2024/06/An%C3%A1lisis-de-la-sequ%C3%ADa-en-Jalisco-por-medio-del-c%C3%A1lculo-del-%C3%8Dndice-de-Sequ%C3%ADa-de-Diferencia-Normalizada-NDDI-2015-%E2%80%932020.pdf>
- La Jornada. (2025, 30 de abril). Sequía en Sinaloa: cierran cinco presas por niveles críticos de almacenamiento. <https://www.jornada.com.mx/noticia/2025/04/30/estados/sequia-en-sinaloa-cierran-cinco-presas-por-niveles-criticos-de-almacenamiento>
- LearnSQL.es. (2024, 3 de octubre). Guía de PostGIS: Ejemplos básicos de consulta de datos geoespaciales. <https://learnsql.es/blog/guia-de-postgis-ejemplos-basicos-de-consulta-de-datos-geoespaciales/>
- MIDE Jalisco. (2025). Número de hectáreas afectadas por la sequía. <https://mide.jalisco.gob.mx/mide/panelCiudadano/detalleIndicador?id=1942&subsistema=1>
- Morales, A. (2024, agosto). PostgreSQL + PostGIS: Solución para la gestión de datos espaciales. MappingGIS. <https://mappinggis.com/2024/08/postgresql-postgis-solucion-para-la-gestion-de-datos-espaciales/>
- NASA Landsat Science. (2025). Data Access. <https://landsat.gsfc.nasa.gov/data/data-access/>
- Organización de las Naciones Unidas para la Alimentación y la Agricultura (FAO). (s. f.). Sistema de Índice de Estrés Agrícola (ASIS). [https://www.fao.org/giews/earthobservation/asis/index\\_1.jsp?lang=es](https://www.fao.org/giews/earthobservation/asis/index_1.jsp?lang=es)
- Ortiz Villamizar, H. Y., & Ramírez Mendoza, Y. P. (2022). Usos generales de Google Earth Engine para el análisis del recurso agua, aire, suelo y biodiversidad. Universidad Nacional Abierta y a Distancia – UNAD. <https://repository.unad.edu.co/bitstream/handle/10596/52419/hortizvil.pdf>

- Polodelconocimiento.com. (s. f.). [Artículo académico sin título visible]. <https://polodelconocimiento.com/ojs/index.php/es/article/download/10164/pdf>
- Sentinel Hub. (2025). Copernicus Data Space Ecosystem. <https://www.sentinel-hub.com/explore/copernicus-data-space-ecosystem/>
- Tiempo.com. (2023, 2 de julio). Índice de sequía en Google Earth Engine. <https://www.tiempo.com/ram/indice-de-sequia-en-google-earth-engine.html>
- UNFCCC. (2025). Las tecnologías de alerta temprana son estratégicas para la adaptación al cambio climático. <https://unfccc.int/es/news/las-tecnologias-de-alerta-temprana-son-estrategicas-para-la-adaptacion-al-cambio-climatico>
- USGS. (2025). EarthExplorer. <https://earthexplorer.usgs.gov/>
- Wikipedia. (2025). Crisis hídrica en México de 2021–2025. [https://es.wikipedia.org/wiki/Crisis\\_h%C3%ADrica\\_en\\_M%C3%A9xico\\_de\\_2021-2025](https://es.wikipedia.org/wiki/Crisis_h%C3%ADrica_en_M%C3%A9xico_de_2021-2025)

## Manual o guía técnica

- Organización Meteorológica Mundial (OMM). (2016). Sistemas de alerta temprana contra la sequía: Guía de aplicación para las autoridades de gestión de los recursos hídricos y los servicios meteorológicos e hidrológicos nacionales. [https://www.droughtmanagement.info/literature/WMO-GWP\\_Manual-de-indicadores\\_2016.pdf](https://www.droughtmanagement.info/literature/WMO-GWP_Manual-de-indicadores_2016.pdf)